


דוגמאות לשימוש במודל שפה במערכות יישוביים

דוגמה 1 - זיהוי דיבור



$$P(S|A) = \frac{P(A|S)P(S)}{P(A)}$$


$$S^* = \operatorname{argmax}_S P(S|A) = \operatorname{argmax}_S = \operatorname{argmax}_S \underbrace{P(A|S)}_{\text{Acoustic Model}} \cdot \underbrace{P_{LM}(S)}_{LM}$$

כנ"ל לתרגום: $A \equiv$ שפת המקור

$P(A|S) \equiv$ מודל תרגום משפה A לשפה S

צריך לבחור מודל יחיד - תצפית לא וודאית ממספר היפותזות

דוגמה 2 - סיווג טקסטים



החלקות - Smoothing

מודל n-gram: קירוב מרקובי

הנחת קירוב מרקובי - ההסתברות למאורע תלויה רק במספר מוגבל של מאורעות אחורה:

$$p(w_i | w_1^{i-1}) = p(w_i | w_{i-n+1}^{i-1})$$

במודל n-gram יש פרמטר לכל n-יה סדורה של מילים שמגדיר את ההסתברות המותנית המתאימה(של מילה בהינתן n-1 המילים הקודמות)

לדוגמה: 3-gram מסתכלים על שתי מילים אחורה - כלומר במודל יש פרמטר לכל שלשת מילים - לדוגמה עבור הטקסט I ate a peach יש פרמטרים כמו $p(\text{peach}|\text{ate}, a)$ $p(a|I, \text{ate})$

נסמן: V - לקסיקון. מספר הפרמטרים: $|V|^n$

הערות מימוש: • בפועל נשמור פרמטרים רק ל-n-יות שנצפו במדגם, וזה תת-לינארי בגודל המדגם.

• יוריסטיקה - בד"כ כאשר השפה מאוד גדולה, נתעלם מרצפים שראינו רק פעם אחת.

נשים ♡: המודל מגדיר התפלגות מולטינומית נפרדת מעל V לכל סדרת מילים מתנה באורך $(n-1)n-1$ (n-יה) - סה"כ $|V|^{n-1}$ התפלגויות שונות)

אומדן MLE לפרמטרים

$$p_{MLE}(w_i | w_{i-n+1}^{i-1}) = \frac{\#(w_{i-n+1}^i)}{\#(w_{i-n+1}^{i-1})}$$

(# - מונה)

לדוגמה - עבור I ate a peach

$$p_{MLE}(\text{peach}|\text{ate}, a) = \frac{\#(\text{times seen "ate a peach"})}{\#(\text{times seen "ate a *"})}$$

נשים ♡ אם ה-n-יה לא נצפתה, אזי נשערך לה הסתברות 0 (נניח בשלב זה שה w_{i-n+1}^{i-1} נצפו). מצב זה יוצר בעיה כאשר יתכנו מאורעות יחסית נדירים, שלא נצפו במדגם, אבל ההסתברות האמיתית שלהן עדיין חיובית.

בגלל הצורה הכפלית של מודל n-gram מספיק שלא נצפה ב-n-יה אחת ונקבל $P(S) = 0$

הפתרון לבעיה הזו - החלקה

החלקה - Discounting

במרחב מסוג מודל שפה, שבו יש הרבה מאורעות נדירים שאפשריים אך לא ייצפו במדגם נתון, נרצה לבצע Discounting - לתת אומדן חיובי למאורעות שלא נצפו, ולמאורעות שנצפו לתת אומדן נמוך מאומדן ה-MLE.

נזכור: באופן יחסי - האומדנים אמינים יותר למונים גבוהים, ועבורים יהיה נכון לעשות הפחתה יחסית קטנה יותר לאומדן MLE

מודל החלקה ראשון - Lidstone

נקודת מבט של הוספת קבוע λ למונה של כל מאורע אפשרי, ונרמול בהתאם:

$$p_{Lid}(x) = \frac{C(x) + \lambda}{|S| + \lambda |X|}$$

(C - מונה)

• עבור $\lambda = 1$: נקרא החלקת Laplace

• כללית: λ הוא פרמטר של השיטה

ההצדקה: אומדן לידסטון מוצדק כאומדן בייסיאני אם מניחים הסתרברות א־פריורית אחידה לכל המאורעות

מתקיים: האומדן הוא אינטרפולציה לינארית בין התפלגות אחידה לאומדן MLE:

$$p_{Lid}(x) = \mu \frac{C(x)}{|S|} + (1 - \mu) \frac{1}{|X|}$$

עבור

$$\mu = \frac{|S|}{|S| + \lambda |X|}$$

μ הוא הפרופורציה של $|S|$ מתוך "המדגם המוגדל"

שימושיות: שיטה מאוד פשוטה ונפוצה לשימוש

מוצדקת: כשיש prior אחיד

מצד שני: תיתן אומדנים מוטים במקרים אחרים - שיכולים לגרום נזק(בפועל - כתלות ברגישות המערכת הכוללת להחלקה)

בפרט - נראה בעייתיות של מודל Lindstone ליישומים שבהם נרצה התנהגות Discounting

ובפרט נראה שהחלקת Lindstone מגדילה את האומדן למאורעות מסויימים ש**נצפו** ביחס לאומדן MLE. כיוון שמתנהגם כאינטרפולציה לינארית - ערך P_{lid} יהיה "באמצע"(מוטה ע"י מקדם האינטרפולציה) בין P_{MLE} להתפלגות יוניפורמית.

נשים ♡: אם $C(x) = \frac{|S|}{|X|}$ - כלומר שכיחות x שווה לשכיחות הממוצעת במדגם - אזי $p_{MLE}(x) = \frac{1}{|X|}$ לכן: עבור $C(x) < \frac{|S|}{|X|}$ נקבל אומדן MLE קטן מאומדן התפלגות יוניפורמית:

$$C(x) < \frac{|S|}{|X|} \implies p_{MLE}(x) = \frac{C(x)}{|S|} < \frac{\frac{|S|}{|X|}}{|S|} = \frac{1}{|X|}$$

מסקנה - ל x ים כנ"ל יתקיים:

$$p_{Lid}(x) > p_{MLE}(x)$$

בניגוד להתנהגות מצופה משיטת discounting