

שיערוך Back off

הרעיון: אם לא מוצאים ב-n-גרם, נחפש ב-1-n-גרם

$$p_B(w'|w) = \begin{cases} p_d(w'|w) & C(w, w') > 0 \\ \alpha(w) p_d(w') & \text{otherwise} \end{cases}$$

$$p\left(w_n \left| \overbrace{w_1, \dots, w_{n-1}}^{w_1^{n-1}} \right. \right) \quad \text{נסמן } n\text{-gram } w_1, \dots, w_n \text{ נשערך:}$$

למשל: הרעיון ל-3-gram

- אם אין סטטיסטיקה (שכיחות 0) ל- w_1^3 , נעשה backoff ל- w_2^3
- אם אין סטטיסטיקה ל- w_2^3 , נעשה backoff ל- w_3

נוסחה כללית ל- P_B ל-n-gram:

$$p_B(w_n | w_1^{n-1}) = \begin{cases} p_d(w_n | w_1^{n-1}) & C(w_1^n) > 0 \\ \alpha(w_1^{n-1}) \cdot p_B(w_n | w_2^{n-1}) & \text{otherwise} \end{cases}$$

עבור יוניגרם: $p_B(w) = p_d(w)$, כי אין למה לעשות backoff...

מה זה α ?

עבור מילה מתנה בודדת:

$$\alpha(w) = \frac{1 - \sum_{w': C(w, w') > 0} p_d(w' | w)}{1 - \sum_{w': C(w, w') > 0} p_d(w')}$$

ועבור סדרת מתנה של $n-1$ מילים:

$$\alpha(w_1^{n-1}) = \frac{1 - \sum_{w_n: C(w_1^n) > 0} p_d(w_n | w_1^{n-1})}{1 - \sum_{w_n: C(w_1^n) > 0} p_d(w_n | w_2^{n-1})}$$

במילים: הסיכוי למילה לא ידועה אחרי w_1^{n-1} חלקי הסיכוי למילה לא ידועה אחרי w_2^{n-1} .

הרעיון הוא שרק אם אין לנו מידע אנחנו עושים backoff.

גישות אינטרפולציה לאומדן

יש לנו כמה דרכים שונות לשערך הסברויות, ואנחנו רוצים לעשות אינטרפולציה בין התוצאות שלהן.

הרעיון: נשלב בצורה ממושקלת מספר אומדנים.

דוגמאות: • שילוב בין מודל ביגרם למודל נאיבי ($0 < \lambda < 1$):

$$p_{\text{int}}(w'|w) = \lambda \cdot p_{ML}(w'|w) + (1 - \lambda) \cdot P(w')$$

• מודל יוניגרם לטקסטים ברפואה: נשלב מודל שנלמד מטקסטים ברפואה למודל מטקסטים כלליים:

$$p(w) = \lambda \cdot P_{\text{med}} + (1 - \lambda) \cdot p_{\text{gen}}(w)$$

• באופן דומה לשקלול מספר מודלים:

$$p(w_3|w_1, w_2) = \lambda_1 \cdot p(w_3|w_1, w_2) + \lambda_2 \cdot p(w_3|w_2) + \lambda_3 \cdot p(w_3)$$

$$\sum_{i=1}^3 \lambda_i = 1 \text{ כך ש}$$

איך מכיילים?

• במקרה פשוט, של מעט פרמטרים λ_i , ניתן לבצע כיול אמפירי ע"י ניסוי מספר ערכים.

נשים ♡: במודל n -gram ניתן לקבוע צירוף מקדמים שונה לכל התפלגות, כלומר עבור כל מאורע מתנה.

בפרט: נצפה לערכי λ אופטימליים גבוהים יותר מאורעות מתנים שכיחים יותר.

ניתן לקבץ מאורעות מתנים לפי שכיחויות ולכייל מקדמים ביחד לכל קבוצה.

• יש מודלים של אינטרפולציה שעבורם קיימים אלגוריתמים יעילים לכיוול המקדמים.

בפרט: ל n -gram יש אלגוריתם ME

משתנים חבויים - Hidden Variables

לפעמים נרצה לחשב אספקטים נוספים של התופעה, שאנחנו לא צופים בהם, כדי למדל יותר טוב את התופעה.

סכימה כללית

נתונה תופעה נצפית Y , בד"כ מורכבת $y = (y_1, \dots, y_n)$.

דוגמה: סקירת מילים/ידיעה/מסמך

מניחים שקיימת התפלגות משותפת של Y עם משתנה חבוי נוסף X

דוגמה: הדסק במערכת שבו נכתבה הידיעה

בד"כ נתעניין ב- X דיסקרטי שמקבל מספר סופי של ערכים "אטומיים".

בתהליך הגנרטיבי שנניח: כדי לייצר תצפית $y \in Y$ קודם נבחר $x \in X$ לפי $p(x)$, ואח"כ נייצר y לפי $p(y|X=x)$.

שימושים במודלים חבויים

כללית: גם כשאין שימוש לערכי X , מידול בעזרת X יכול לשפר את מידול Y .

במקרים אחרים יש עניין יישומי בערכי X :

- בסיטואציות אופייניות של למידה/סיווג:

1. למידה/סיווג מבוקר/מפוקח (Supervised):

ערכי X ידועים, ויש מדגם אימון שבו לכל $y \in Y$ שנצפה ידוע(מתוייג) מה ערך $x \in X$ המתאים לאותו y .

– ממדגם כזה נשערך את ההתפלגות המשותפת.

– יישום: בהינתן y , לשערך את $p(x|y)$. ובפרט: לסווג את y לפי המתאים.

2. למידה לא מפוקחת (Unsupervised):

לא ידועה מראש זהות ערכי X , ואין מדגם מתוייג.

המטרה: לקבל(קלסטרינג) את התצפיות של y לפי ערכי $x \in X$ שכנראה ייצרו אותם.

מטרת הלמידה: שערך θ , אוסף הפרמטרים של $p(x, y; \theta)$

מודל חבוי - עירוב היסטוגרמות Mixture of Histograms

(זה בעצם עירוב של מולטינומים)

נמחיש: כמודל ליצירת מסמכים (Y) לפי נושאים (X).

נתייחס למסמך כהיסטוגרמת שכיחויות של המילים שמופיעות בו(זה המודל המולטינומי שלמדנו ליוניגרם).

נסמן: המילים נלקחות ממילון בגודל v : $w_1, \dots, w_v$

מדגם מסמכים: $y = y_1, \dots, y_N$ (מסמכים במדגם)

נניח אי תלות בין המסמכים.

ייצוג מסמך y_t : כהיסטוגרמה של v שכיחויות $y_t = (n_{t1}, n_{t2}, \dots, n_{tv})$ כאשר n_{tk} היא שכיחות המילה w_k במסמך y_t

לפשטות: נניח אורך מסמכים קבוע n : $\forall_t \sum_{k=1}^v n_{tk} = n$

מודל עם משתנה חבוי

נניח קיום:

- מ"מ נוסף X עם ערכים $x_1, \dots, x_{|X|}$ (בדוגמה המסמכים: מייצג קטגוריה, או קלסטר)
- התפלגות משותפת $p(x, y; \theta)$

תהליך גנרטיבי ליצירת מסמך

1. נבחר $x \in X$ (קטגוריה) לפי התפלגות $p(x) = P(X = x)$
 2. נקבע את המילים y לפי התפלגות $p(y_t | X = x)$
- בפרט: נניח עבור $p(y_t | x)$ מודל מולטינומי נפרד לכל $x \in X$

בהתאם - הפרמטרים θ של המודל

$$\forall x_i \in X p(x_i)$$

$$\forall x_i \in X \forall w \in w_1, \dots, w_v p(w_k | x_i)$$

לפי המודל המולטינומי:

$$p(y_t | x_i) = \prod_{k=1}^v p(w_k | x_i)^{n_{tk}}$$

נתעניין ב3 שאלות:

1. $p(y_t; \theta)$ - הסתרורות יצירת תצפית
2. $p(x_i | y_t; \theta)$ - הסתרורות הסיווג/שיוך לקלסטר
3. אומדן $\hat{\theta}_{ML}$ - נסיון ערכי ML לפרמטרים

¹מימין לנקודה-פסיק(;): רושמים את הפרמטרים של ההסתברות