

דורות של מודלי סיווג (Sentiment Classification)

Software 1.0: כותבים קוד שמבצע את הסיווג

Software 2.0: מאמנים מודל

Software 3.0: כותבים פרומפט ל LLM

גדילה של המודל

יש שלושה צירים עיקריים, בהם המודלים גדלים

- כמות הפרמטרים החופשיים
- כמות הנתונים הדרושה
- עלויות האימון

היררכיית המושגים

- בינה מלאכותית Artificial Intelligence - אוסף רחב מאוד של טכניקות שמטרתן לייצר התנהגויות המדמות אינטליגנציה.
- למידת מכונה Machine Learning - טכניקות שבהן מלמדים כללים מתוך דוגמאות.
- למידה עמוקה Deep Learning - תחום בתוך למידת מכונה.

סוגי בעיות של AI צריך לפתור, לפי התפלגות דוגמאות

התפלגות הדוגמאות לא אחידה. יש מקרים מאוד נפוצים ומקרים מאוד נדירים. זה אומר שצריך לפתור בעיה אחת עבור הדוגמאות הנפוצות ובעיה מאוד שונה עבור הדוגמאות הנדירות:

Memorize בצד של הדוגמאות הנפוצות, אנחנו הרבה פעמים נבחנים על דברים שכבר ראינו.

- בשביל זה לא צריך למידה מסובכת אלא האסטרטגיה הנכונה כאן היא שינון, לצורך retrieval.

Generalize באמצע הסקאלה יש מקרים שדומים לדברים שכבר ראינו, אבל לא בדיוק - וצריך להכליל (Generalize)

- למידת תבניות
- יותר קשה לבטוח בתוצאות
- רוב ההתקדמויות המודרניות בתחום AI נכנסות לקטגוריה הזאת

Optimize בצד השני יש מקרים עם מעט מאוד דוגמאות קרובות - אולי אפילו בכלל לא. כאן צריך לעשות הסקות.

- מודלים מכאניסטים וקאזלים
- תכנות קלאסי - אלגוריתמים של חיפוש ואופטימיזציה
- יותר קל לבטוח בתוצאות

סוגים של למידה מכונה

- למידה מונחית Supervised Learning - למידה של כלל מתוך דוגמאות המורכבות מקלטים ופלטות.
- למידה לא מונחית Unsupervised Learning - למצוא ייצוג של dataset שיהיה מועיל ל"משהו". למשל להוציא דברים חשובים מתוך מידע מורכב.
- למידת חיזוקים Reinforcement Learning - מונחית באופן חלש. למידה אינטראקטיבית. סוכן שמבצע פעולות ולומד מתוך זה מה הוא צריך לעשות ומה אסור לו לעשות. הפעולות שהסוכן מבצע יכולות לשנות את הסביבה.¹

רקע מתמטי

הקורס בנוי על שלושה תחומים מתמטיים

1. אלגברה לינארית
2. חשבון דיפרנציאלי ואינטגרלי
3. הסתברות

אלגברה לינארית

נניח $v \in \mathbb{R}^d$ וקטור רב ממדי, $A \in \mathbb{R}^{d \times d}$ מטריצה שמייצגת טרנספורמציה על הווקטור. רוב הווקטורים משנים את הכיוון של הווקטור ואולי גם את הגודל. אבל יש ווקטורים שהכיוון שלהם לא משתנה. הווקטורים האלה נקראים ווקטורים עצמיים, והשינוי בגודל שלהם נקראים

בצורה פורמלית: מחפשים $v \in \mathbb{R}^d$ וסקלרים $\lambda \in \mathbb{R}$ כך ש $Av = \lambda v$. מבצעים זאת ע"י פתרון מערכת משוואות:

$$Av = \lambda Iv$$

$$(A - \lambda I)v = 0$$

כדי לנרמל נקבע $\|v\| = 1$. נשים לב ש λ יכול להיות שלילי.

- תכונות אם המטריצה סימטרית ($A^T = A$), הווקטורים העצמיים הם אורתוגונליים
- ערכים עצמיים יכולים להיות מרוכבים

¹בקורס הזה לא נלמד Reinforcement Learning

מטריצה חיובית

- הגדרה מטריצה תיקרה חיובית אם לכל וקטור $z \in \mathbb{R}^d$ מתקיים $z^T A z > 0$
- טענה כל ערך עצמי λ של מטריצה חיובית A הוא חיובי $\lambda > 0$
- טענה אם כל הערכים עצמיים של מטריצה סימטרית $A \in \mathbb{R}^{d \times d}$ הם חיוביים ושונים, אזי המטריצה חיובית.

משתנים מקריים רב ממדיים

- תזכורת התפלגות משותפת יהיו שני משתנים מקריים:

- X מקבל ערכים $x^1, \dots, x^k$ בהתפלגות $P(X = x)$
- Y מקבל ערכים $y^1, \dots, y^l$ בהתפלגות $P(Y = y)$

נניח שיש d משתנים כאלה X_d . ההתפלגות המשותפת היא

$$P(X_1 = x_1, \dots, X_d = x_d)$$

הווקטור X_d הוא משתנה מקרי רב ממדי

- הגדרה שונות משותפת של זוג משתנים (משתנה מקרי דו ממדי) היא:

$$\text{Cov}(X, Y) = E(X \cdot Y) - E(X) E(Y)$$

נסמן $\mu_X = E(X)$ ו $\mu_Y = E(Y)$, ונוכל לכתוב

$$\text{Cov}(X, Y) = E[(X - \mu_X) \cdot (Y - \mu_Y)]$$

מטריצת השונות היא:

$$\begin{bmatrix} \text{Cov}(X, X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & \text{Cov}(Y, Y) \end{bmatrix}$$

והבכללה ל d מימדים:

$$\text{Cov}(X) = \begin{pmatrix} \text{Cov}(X_1, X_1) & \dots & \text{Cov}(X_1, X_d) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \dots & \text{Cov}(X_d, X_d) \end{pmatrix}$$

נשים לב שהערכים על האלכסון הם השונות של הרכיבים.

אפשר לייצג את זה בצורה יותר קומפקטית באמצעות ווקטורים. יהי $\mu = E[X]$ אזי: $(\mu_1, \dots, \mu_d)^T$

$$\Sigma = E[(X - \mu)(X - \mu)^T]$$

מכיוון שכל אחת מהשונויות המשותפות היא סימטרית, המטריצה כולה היא סימטרית - ולכן הווקטורים העצמיים שלה אורתוגונליים.

טענה מטריצת השונות היא חיובית.

הוכחה Σ מטריצת שונות משותפת ורוצים להוכיח שהיא חיובית - כלומר לכל $z \in \mathbb{R}^d$ מתקיים $z^T \Sigma z \geq 0$.

נתחיל מצד שמאל:

$$z^T \Sigma z = z^T E \left[(X - \mu) (X - \mu)^T \right] z$$

נכניס את הווקטורים לתוחלת:

$$z^T \Sigma z = E \left[z^T (X - \mu) (X - \mu)^T z \right]$$

מכיוון ש $z^T (X - \mu)$ הוא סקלר:

$$z^T \Sigma z = E \left[z^T (X - \mu) \left((X - \mu)^T z \right) \right]$$

מכיוון ש $(z^T (X - \mu))^T = (X - \mu)^T z$ (שחלוף של סקלר הוא הסקלר עצמו) אפשר לכתוב:

$$z^T \Sigma z = E \left[\left(z^T (X - \mu) \right) \left(z^T (X - \mu) \right)^T \right]$$

$$z^T \Sigma z = E \left[\left(z^T (X - \mu) \right)^2 \right]$$

ולכן הערכים העצמיים חיוביים - ומכיוון שהמטריצה סימטרית, היא חיובית.

התפלגות נורמלית (Gaussian) רב מימדית

תזכורת: בהתפלגות נורמלית רגילה $X \sim N(\mu, \sigma^2)$ פונקציית הצפיפות היא:

$$f(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2}$$

בהתפלגות נורמלית רב מימדית $X \sim N(\mu, \Sigma)$ פונקציית הצפיפות היא:

$$f(x) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right)$$

זה נראה כמו פעמון d -ממדי, כאשר ההתפלגות השולית על כל משתנה² היא התפלגות גאוסיאנית חד מימדית (פעמון חד ממדי)

²כלומר ההתפלגות שלו כאשר מתעלמים מהמשתנים האחרים

תזכורת משמעות הפרמטרים:

μ התוחלת - מציגה את כל ההתפלגות. קובעת את מרכז ההתפלגות.
 σ השונות - הפיזור סביב האפס. ככל שהיא יותר גדולה, הפעמון יותר נמוך.

במקרה הרב ממדי, התוחלת μ עדיין קובעת את המרכז. אבל הסיפור של השונות קצת יותר מורכב כי יש לנו מטריצה של שונות משותפת. במקרה הדו מימדי (bivariate Gaussian) צורת הפעמון, בהסתכלות מלמעלה, הוא אליפסה:
• עבור $\Sigma = I$ האליפסה היא בעצם עיגול.

• עבור שונות משותפת שהיא מטריצה אלכסונית³ - למשל $\Sigma = \text{diag}(1, 2)$ - האליפסה מיושרת לצירים. ההתפלגות המשותפת שווה למכפלת ההתפלגויות השוליות.

• אבל אם יש שונות משותפת שונה מאפס לשני המשתנים, האליפסה "מוטה".

תכונות תהי $X = (X_1, \dots, X_d)^T$ התפלגות גאוסיאנית

• כל חתך $X_i | (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_d)$ גם הוא גאוסיאני (ממימד $d - 1$)

• החתך $\int_{-\infty}^{\infty} f_X(x_1, x_2, \dots, x_d) dx_1$ גם הוא גאוסיאני (ממימד $d - 1$)

נגזרות במרחבים רב מימדיים

הגדרה הגרדיאנט. תהיה פונקציה $f: \mathbb{R}^d \rightarrow \mathbb{R}$, ווקטור $x = [x_1, \dots, x_d]$. הגרדיאנט הוא ווקטור הנגזרות ביחס לכל אחד מהמשתנים:

$$\nabla f(x) = \left[\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_d} \right]$$

תכונה הגרדיאנט מצביע על הכיוון עם השיפוע החד ביותר⁴

הוכחה נסמן $D_u(f(x))$ - כמה הפונגציה משתנה בכיוון u (נניח ש f גזירה בכל כיוון):

$$D_u(f(x)) = \lim_{h \rightarrow 0} \frac{f(x + hu) - f(x)}{h}$$

נכתוב את f ע"י טור טיילור:

$$f(x + hu) \approx f(x) + \nabla f(x) hu + \epsilon(h)$$

אז:

$$D_u(f(x)) = \lim_{h \rightarrow 0} \frac{f(x) + \nabla f(x) hu + \epsilon(h) - f(x)}{h} = \nabla f(x) u$$

³יש ערכים על האלכסון, אבל כל שאר הערכים הם אפס.
⁴הגרדיאנט מצביע על כיוון העליה - והכיוון ההפוך הוא כיוון הירידה

למידת מכונה
89-2511-02

מקליד: עידן אריה
מרצה: פרופ' גל צ'צ'יק
תאריך: 2026-03-16

נשתמש באי שוויון קושי $\|ab\| \leq \|a\| \|b\|$ ו $\|u\| = 1$:

$$|D_u(f(x))| = \|\nabla f(x) u\| \leq \|\nabla f(x)\|$$

וזה הכי גדול כאשר שני הווקטורים קו-לינארים - כלומר נקבל ערך מקסימלי בכיוון של הגרדיאנט.

למה זה חשוב? כי אם יש לנו פונקציה מאוד מורכבת, אם נעשה צעדים במורד הגרדיאנט נוכל די מהר להגיע למינימום מקומי.