

למידה מונחית

נתון: training data - זוגות של דגימות ותגיות (x_i, y_i) עבור $x \in \mathcal{X}, y \in \mathcal{Y}, i = 1 \dots n$. הנדגמים מתוך התפלגות לא ידועה $P(x, y)$. זה משקף מיפוי $f: \mathcal{X} \rightarrow \mathcal{Y}$.

המטרה: למצוא היפוטזה $h: \mathcal{X} \rightarrow \mathcal{Y}$ שחושפת את f .

מגדירים: "loss" - $\ell(h(x), y)$ - שמודדת את חוסר ההתאמה

מחפשים: h שתמזער את תוחלת הloss

$$\mathbb{E}_{P(x,y)}[\ell(h(x), y)] = \sum_{(x,y)} \ell(h(x), y) p(x, y)$$

בד"כ h היא לא סתם פונקציה, אלא מגיעה מתוך משפחה של היפוטזות $\mathcal{H}$. ההיפותזות במשפחה $\mathcal{H}$ יש פרמטרים שונים (למשל - מקדמי פולינומים), ותהליך האימון מוצא את הפרמטרים הנכונים. יש שני שלבים:

- שלב האימון training phase - בהינתן training data (x_i, y_i) אלגוריתם הלמידה מוצא מודל h_w .
- שלב ההסקה inference phase - מפעילים את המודל על data חדש x , ומוצאים את y שלו לפי $h_w(x)$.

סוגים עיקריים

- כאשר הפלט הוא קטגוריות, זה נקרא Classification. לדוגמה - זיהוי אובייקטים. $\mathcal{X}$ הוא כל התמונות האפשריות, ו $\mathcal{Y}$ הוא סיווגי התמונה האפשריים (למשל - כלב, חתול, זברה).
- כאשר הפלט הוא משתנה רציף זה נקרא Regression. למשל - נהיגה אוטונומית. $\mathcal{X}$ זה הוידאו והחיישים, ו $\mathcal{Y}$ זה כמה לסובב את ההגה.

רגרסיה פולינומית

יש "כלל" בעולם - כלל שאנחנו לא יודעים. מה שכן יש לנו זה דוגמאות שנדגמו מתוך הכלל הזה - לקחו ערכי x ולכל אחד דגמו y שהוא ערך הפונקציה בתוספת רעש אקראי. לא נוכל לגלות את הכלל באמת - אבל כן נוכל לגלות קירוב שלו. נבחר את $\mathcal{H}$ שלנו להיות משפחת הפולינומים:

$$h_w(x) = w_0 + w_1x + w_2x^2 + \dots + w_dx^d$$

למה דווקא פולינומים? בגלל שאם פונקציה חלקה מספיק, נוכל לקרב אותה ע"י פולינומים באמצעות קירוב טיילור.

בהינתן המקדמים של הפולינום, איך נדע אם הוא קירוב טוב? לא נוכל לבדוק מול הכלל האמיתי (שאינו ידוע) אבל נוכל לבדוק מול המדגם שלנו.
נגדיר loss:

$$\ell(w; x_i, y_i) = (h_w(x_i) - y_i)^2$$

למה בריבוע?

- גם כדי להעניש יותר על הסטייה
 - גם כי זה תמיד חיובי
 - פונקציה חלקה, שקל לעבוד איתה
- השגיאה הכוללת היא הממוצע של loss:

$$Err(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2$$

פולינום ממעלה 0

נתחיל במקרה הכי פשוט - מודל של פולינום ממעלה $d = 0$:

$$h_w(x) = w_0$$

כלומר פשוט קבוע.

מחפשים w_0 שימזער את:

$$\min_w Err(w) = \frac{1}{n} \sum_{i=1}^n (h_w(x_i) - y_i)^2 = \frac{1}{n} \sum_{i=1}^n (w_0 - y_i)^2$$

אם גוזרים, מוצאים שהמינימום הוא פשוט הממוצע:

$$\min_w w_0 = \frac{1}{n} \sum_{i=1}^n y_i$$

פולינום ממעלה 1

פולינום ממעלה אחת הוא פונקציה לינארית $h_w(x) = w_0 + w_1 x$

פולינומים ממעלות יותר גבוהות

אפשר לעלות במעלות ולמצוא ע"י גזירה את מקדמי הפולינום שממזערים את השגיאה. כאשר עולים יותר מדי במעלות, מקבלים מודל לא מוצלח. אבל זה שונה מאשר מעלה נמוכה מדי.

- במעלה נמוכה מדי, השגיאות עקביות - יש להן הטייה (bias)

- במעלה גבוהה מדי, אין שגיאות על training data - הוא עובר דרך כל הנקודות. אבל בד"כ הוא לא מתאים לפונקציה שמנסים למצוא, ורכיב השונות (variance) בשגיאה של התחזיות יהיה גדול.
- המודל ישנן את הרעש של הדגימה.
- אם היינו מגרילים מהכלל נקודות אחרות - הקו היה נראה מאוד שונה.

אופטימיות יתר

הבעיה היא שאנחנו מאפסמים את סט האימון. אבל אנחנו לא מעוניינים להקטין את loss על סט האימון - אנחנו רוצים למזער את loss הכללי.

אנחנו רוצים להקטין את שגיאת ההכללה $Err_{GEN}(w) = \mathbb{E}_{P(x,y)}[\ell(h_w; x_i, y_i)]$ - לא את שגיאת האימון $Err_{Train}(w) = \frac{1}{n} \sum_{i=1}^n \ell(h_w; x_i, y_i)$.

אם אנחנו יותר מדי אופטימים, אז לא רק שהמודל גרוע - אלא אנחנו גם לא יודעים שהוא גרוע.

נבחר מתוך training data (או בנוסף אליו) אוסף דוגמאות שיהיו test data. עליו לא נעשה אימון, ונבדוק את $Err_{Test}(w)$ עבור ההיפותזה שמצאנו מה training data.

נשים לב שעבור $d = n - 1$ יש לנו n פרמטרים חופשיים בפולינום $(w_0, w_1, \dots, w_n)$ ולכן שגיאת האימון תהיה אפס - ושגיאת test תקפוץ. הפער הזה נקרא Generalization Gap, או overfitting.

אנחנו רוצים לבחור מעלה של הפולינום (בהכללה - כמות פרמטרים במודל) שתמזער את Err_{Test} . אבל צריך לשים לב שיכול להיות מצב שמה שאנחנו מחפשים בכלל לא נמצא בנתונים שלנו, ואז אין באמת מה לעשות.

איך מצמצמים Overfitting?

פתרון 1 - עוד נתונים.

- ככל שיש יותר נתונים, אפשר לדייק יותר.
- במודלים של Deep Learning יש הרבה עבודה להשיג כמויות אדירות של נתונים.
- יש תחומים בהם יש מעט מאוד נתונים.

פתרון 2 - regularization

ככל שעולים במעלות של הפולינום, המקדמים נעשים יותר גבוהים. המודל מנצל את העובדה שהוא יכול להיות מאוד מאוד עקמומי כדי לעבור דרך כל הנקודות, וזה מתבטא במקדמים מאוד גבוהים.

דרך אחת להגביל את המודל הייתה להגביל את המעלה. אבל דרך אחרת יכולה להיות להרשות מעלה מאוד גבוהה - אבל להעניש מקדמים גבוהים.

נוסיף עוד מרכיב לפונקציית השגיאה:

$$Err(w) = \underbrace{\sum_{i=1}^n (h_w(x_i) - y_i)^2}_{\text{loss}} + \underbrace{\frac{\lambda}{2} \|w\|^2}_{\text{regularizer}}$$

$$\|w\|^2 = w^T w = w_0^2 + w_1^2 + \dots + w_d^2 \quad \text{תזכורת:}$$

הערה: לא מחלקים את loss ב n כאן כדי שכשכמות הנתונים תגדל - המשקל של loss יקטן. אבל אפשר גם לחלק ב n (לעשות ממוצע)

λ כאן זה מקדם ששולט ברגולריזציה.

- ככל שהוא יותר קטן הרגולריזציה פחות משפיעה - כשהוא אפס, אין רגולריזציה.
- מצד שני, כשהוא שואף לאינסוף המשקל של loss נעלם ומקבלים את פולינום האפס. כלומר יש לנו כאן tradeoff.

סיכום ביניים - מרכיבים עיקריים

- סט אימון training data - n דגימות מתויגות (x_i, y_i) מתוך התפלגות לא ידועה $P(x, y)$.
- סט של היפותזות $h \in \mathcal{H}$, בד"כ מאופיינות ע"י סט פרמטרים w שלומדים מתוך הנתונים.
- Expressivity - כמה סט הפרמטרים של מחלקת ההיפותזות עשיר.
- פונקציית loss $\ell(w; x, y)$ שרוצים למזער עבור w .
- - בעיית אופטימיזציה. בד"כ לא יהיה פתרון אנליטי ונצטרך להשתמש בשיטות נומריות.
- סט בדיקה test data. משמש כדי להעריך את תוחלת השגיאה.
- - מה שבאמת אנחנו רוצים זה תוחלת השגיאה הכללית - אבל אנחנו מוגבלים לנתונים שיש לנו.
- - הכללה Generalization - הפער בין השגיאה על סט האימון לשגיאה על סט הבדיקה (ובכלל)

סוגי שגיאות

- | | |
|-----------------------|---|
| f | הפונקציה האמיתית |
| $f_{\mathcal{H}}$ | הפונקציה האופטימלית בכלל, מתוך משפחת ההיפותזות שלנו $\mathcal{H}$, ללא קשר למדגם הנתונים שיש לנו |
| $f_{\mathcal{H},S}$ | הפונקציה האופטימלית עבור המדגם המסויים |
| $f_{\mathcal{H},S}^*$ | הפונקציה שהצלחנו למצוא עבור המדגם המסויים |
- שגיאת האופטימיזציה - $|f_{\mathcal{H},S} - f_{\mathcal{H},S}^*|$
 - שגיאת ההכללה - $|f_{\mathcal{H}} - f_{\mathcal{H},S}|$ - יכול להיות שנמצא היפותזה שטובה לסט האימון, אבל יהיה פער בין זה לבין תוחלת השגיאה הכללית.
 - שגיאת הקירוב - $|f - f_{\mathcal{H}}|$ - יכול להיות שאין לנו אפשרות בכלל למצוא הכללה טובה תחת המגבלות שיש לנו.

מבחן

שאלה	מה ההבדל בין שגיאת ההכללה לשגיאת הבדיקה?
תשובה	שגיאת ההכללה זה מול הפונקציה האמיתית, ושגיאת הבדיקה זה מול סט הנתונים ששמנו בצד לבדיקה.
שאלה	מה יקרה אם נחליף את הרגולריזר $\ell_2 = \sqrt{\sum_j w_j^2}$ ב- $\ell_1 = \sum_j w_j $?
תשובה	כשיש לנו ריבוע, אם יש ערכים קרובים לאפס הרגולריזציה לא טורח להביא אותם ממש לאפס. אבל אם יש ערך מוחלט כן, ונקבל יותר אפסים.
שאלה	מה עושים אם הפונקציה גזירה, אבל אי אפשר למצוא נקודת מינימום באופן אנליטי?
תשובה	gradient descent.
שאלה	מה הבעיה של בחירת עצמת הרגולריזציה לפי test set?
תשובה	נקבל overfitting על test set.

תורת החלטות בייסיאנית

נראה ששימוש אחד לתורת ההחלטות הבייסיאנית היא למידת פרמטרים. בהינתן מדגם של דוגמאות, נרצה ללמוד תכונות של העולם. דוגמה: רוצים להחליט אם לקחת מטרייה או לא לקחת מטרייה. יש מצב אמיתי של העולם (ירד או לא ירד גשם) שישפיע על העלות של כל החלטה.

הגדרה

- סט של צבי עולם לא חופפים $\Omega = \{\omega_i\}$.
- הם לא חופפים
- הם מכסים את כל האפשרויות
- תצפיות $S_n = \{x_1, \dots, x_n\}$. דוגמאות אמפיריות
- מודל הסתברותי $P(S_n|\omega)$ ו- $P(w)$. המודל אינו תלוי בתצפיות - מניחים ידע מלא על ההתפלגויות האלה.
- פעולות אפשריות $A = \{\alpha_1, \dots, \alpha_k\}$
- עלויות $\Lambda = \{\lambda(\alpha_k|\omega_j)\}$

חוק בייס

$$P(\omega|x) = \frac{P(x|\omega)}{P(x)} P(\omega)$$

כאשר:

$P(\omega)$ - prior - מה ההסתברות להיות ב ω ללא קשר לתצפיות

$P(x|\omega)$ - likelihood - הסיכוי לקבל תצפית x בהינתן ω

$P(\omega|x)$ - posterior - ההסתברות שאנחנו ב ω בהינתן התצפית x

המטרה ב Bayes decision theory היא לתכנן אסטרטגיה $\alpha(S_n)$ שתקבע איזה פעולה α לקחת בהינתן תצפיות S_n כדי למזער את העלות.

הגדרה - conditional risk

המחיר המותנה לפעולה α_k הוא:

$$R(\alpha_k|x) \equiv \mathbb{E}_{P(\omega|x)}[\lambda(k|\omega)] = \sum_{\{\omega_j \in \Omega\}} \lambda(\alpha_k|\omega_j) P(\omega_j|x)$$

זה בעצם המחיר לפעולה α_k .

נשים לב ש $P(\omega_j|x)$ לא ידוע לנו ישירות - מחשבים לפי חוק בייס:

$$P(\omega_j|x) = P(x|\omega_j) \frac{P(\omega_j)}{P(x)} = P(x|\omega_j) \frac{P(\omega_j)}{\sum_k P(x|\omega_k) P(\omega_k)}$$

במילים: אנחנו רוצים לבחור את הפעולה שבתוחלת תביא את העלות הכי נמוכה.

דוגמאות

דוגמה 1 - מחיר אפס או אחד

המטרה שלנו היא לנחש מה מצב העולם. אם טועים משלמים מחיר קבוע (1):

$$\lambda(\alpha_k|\omega_j) = 1 - \delta_{kj}$$

כאשר $\delta_{kj} = 1$ עבור $k = j$ אחרת $\delta_{kj} = 0$

$$R(\alpha_k|x) = \dots = 1 - P(\omega_k|x)$$

$R(\alpha_k|x)$ מינימלי כאשר לוחקים α_k עבורו $P(\omega_k|x)$ מקסימלי (maximum posterior)

דוגמה 2 - שני מצבי עולם ושתי פעולות

מטריצת המחרים היא 2×2 שנסמן $\lambda_{k,j} = \lambda(\alpha_k | \omega_j)$. המחריר לכל פעולה הוא:

$$R(\alpha_1 | x) = \lambda_{11} P(\omega_1 | x) + \lambda_{12} P(\omega_2 | x)$$

$$R(\alpha_2 | x) = \lambda_{21} P(\omega_1 | x) + \lambda_{22} P(\omega_2 | x)$$

אנחנו רוצים לבחור את α_1 אם הסיכון שלה קטן מ α_2 :

$$\lambda_{11} P(\omega_1 | x) + \lambda_{12} P(\omega_2 | x) < \lambda_{21} P(\omega_1 | x) + \lambda_{22} P(\omega_2 | x)$$

$$(\lambda_{12} - \lambda_{22}) P(\omega_2 | x) < (\lambda_{21} - \lambda_{11}) P(\omega_1 | x)$$

$$\frac{P(\omega_1 | x)}{P(\omega_2 | x)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}$$

ונפעיל את חוק בייס:

$$\underbrace{\frac{P(x | \omega_1)}{P(x | \omega_2)}}_{\text{Likelihood ratio}} > \underbrace{\frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}}_{\text{Decision boundary}}$$

כלומר עלינו לחשב את likelihood ratio ולבדוק האם הוא מעל או מתחת לסף הכרעה.

מה קורה כשיש הרבה תצפיות?

נכליל את הדוגמה למצב שיש הרבה תצפיות $x_1, \dots, x_n$:

$$\underbrace{\frac{P(x_1, \dots, x_n | \omega_1)}{P(x_1, \dots, x_n | \omega_2)}}_{\text{Likelihood ratio}} > \underbrace{\frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}}_{\text{Decision boundary}} = \Theta$$

אם נניח שהתצפיות בלתי תלויות ושוות התפלגות בהינתן מצב העולם ω (i.i.d):

$$\frac{\prod_i P(x_i | \omega_1)}{\prod_i P(x_i | \omega_2)} > \Theta$$

מבחינה נומרית, כאשר מכפילים מספר גדול של הסתברויות עלולים להתקל בבעיות של ייצוג מספרים קטנים. לכן נגדיר $\Theta' = \log \Theta$ ונעשה:

$$\sum_i \log \frac{P(x_i | \omega_1)}{P(x_i | \omega_2)} > \Theta'$$

זה נקרא log-likelihood ratio.