

## למידה לא מפוקחת

האם אפשר ללמוד לעשות ייצוג של הידע גם בלי תוויות?  
בתור בני אדם, אנחנו לומדים שפה ע"י שמיעה גם בלי שנותנים לנו label. אנחנו מוצאים תבניות בנתונים גם בלי התיוג.

הגדרה: בהינתן  $\mathcal{D} = \{x_1, \dots, x_n\}; x_i \in \mathbb{R}^d$  דוגמאות i.i.d, למידה לא מפוקחת מוצאת מבניות בנתונים.

יש כמה סוגים של למידה לא מפוקחת:

- למצוא את ההתפלגות שייצרה את הנתונים.
- להוריד את מספר המימדים
- לחלק את המרחב של  $N$  הדוגמאות למספר אזורים ככה שהנקודות באותו cluster קרובות אחת לשנייה.

יש כל מיני גישות לחלק לcluster. נדבר כאן על prototyp based clustering.

- הרעיון: יש נקודה שמייצגת את cluster ונקראת "prototype".
- הנקודה הזאת היא לא בהכרח אחת מהדגימות.
- הנקודות בכל cluster קרובות לprototype.
- הדגימות הן בעצם spatial noise שמוסף לprototype.

בצורה פורמלית:

- נתון: נתונים  $\mathcal{D} = \{x_1, \dots, x_n\}$  כאשר  $x_i \in \mathbb{R}^d$
- היפרפרמטר  $K \in \mathbb{N}^+$  שמגדיר את מספר הcluster שאמורים לגלות.
- המטרה: למצוא  $K$  prototype  $\mu^* = \{\mu_1, \dots, \mu_K\}$  כאשר  $\mu_i \in \mathbb{R}^d$ .
- $\mu^*$  ממזער את סכום ריבועי המרחקים של הנקודות ב  $\mathcal{D}$  מהprototype שלהם:

$$\mu^* = \arg \min_{\mu} \sum_{i=1}^n \min_{j \in \{1, \dots, K\}} \|x_i - \mu_j\|_2^2$$

- נקודות שייכות לprototype הקרוב ביותר לפי (ריבוע) מרחק אוקלידי:

$$\text{cluster}(x_i) = \arg \min_j \|x_i - \mu_j\|_2^2$$

הבעיה הזאת מוגדרת היטב, אבל מאוד מורכבת חישובית -  $\mathcal{O}(n^{Kd+1})$ . כלומר גם עבור שני מימדים  $K = 2$  זה יוצא  $\mathcal{O}(n^5)$ ! במקום זה נרצה יוריסטיקה איטרטיבית. אלגוריתם k-means הוא אלטרנטיבה כזאת.

- האלגוריתם: אתחול: בוחרים  $K$  prototype התחלתיים  $\mu^0 = \{\mu_1^0, \dots, \mu_K^0\}$ .

• כל איטרציה ( $t = 1, \dots$ ) כוללת שני צעדים:

1. צעד E - משייכים כל דגימה  $x_i$  לcluster של prototype הקרוב ביותר:

$$\text{cluster}^{(t)}(x_i) = \arg \min_j \|x_i - \mu_j^{t-1}\|_2^2$$

2. צעד M - מחשבים מחדש את prototype:

$$c_j = \{x_i \mid \text{cluster}^{(t)}(x_i) = j\} \quad \mu_j^t = \frac{1}{|c_j|} \sum_{x \in c_j} x$$

• ממשיכים עד להתכנסות - כלומר עד שמתקיים:

– הנקודות של prototype לא השתנו.

– השייך לcluster לא השתנה.

נשים לב שאלו תנאים שקולים.

האם מובטח שהאלגוריתם יתכנס? כן!  
יש objective function:

$$J(\mu, r) = \sum_{i=1}^n \sum_{j=1}^K r_{ij} \|x_i - \mu_j\|_2^2$$

כאשר:  $\mu_j \in \mathbb{R}^d$  centroid

$r \in \{0, 1\}^{n \times d}$  - שיוכים -  $r_{ij} = 1$  אם  $x_i$  משייך לcluster  $j$ . אחרת  $r_{ij} = 0$ .

הרעיון של ההוכחה:

• צעד לא יכול להגדיל את  $J$

•  $J \geq 0$

• מספר הcluster האפשריים הוא סופי

למה צעד לא יכול להגדיל את  $J$ ? צעד E משייך לפי מה שמקטין את הממוצע (כלומר את  $J$ ) וצעד M בוחר את  $\mu_j$  להיות הממוצע - שהוא הרי המספר שממזער את סכום המרחקים<sup>1</sup>.

סיכום: יתרונות: • מובטח שהוא יתכנס

• מתכנס מאוד מהר

• בעיות: ההתכנסות תלויה באיתחול - יכולים להיות איתחולים שמביאים

אותנו למינימום מקומי. אפשר להתגבר על זה באמצעות ביצוע

מספר נסיונות ולקיחת התוצאה שבה סכום המרחקים של כל

נקודה מהprototype שלה הכי נמוך.

<sup>1</sup>אפשר להוכיח ע"י גזירה.

**למידת מכונה**  
**89-2511-02**

מקליד: עידן אריה  
מרצה: ד"ר אורן גליקמן  
תאריך: 2026-06-08

- 
- בחירת  $K$  לא נכון תוביל לתוצאה לא נכונה.
  - לפעמים cluster שנראים לעין (לפחות בדו-מימד) הם לא cluster מבחינת נורמה.
  - במימד גדול, נורמת  $L_2$  מתחילה לאבד משמעות.

מה עושים אם רוצים להיות מסוגלים לתפוס צורות שונות?

- Gaussian Mixture Model - משתמש במטריצות שונות משותפת.
- DBSCAN - ממזער מרחקים בין הנקודות (ולא למרכזים)
- Hierarchical Clustering - ממדל לפי dendrogram (עצים)

## Gaussian Mixture Model

אלגוריתם Gaussian Mixture Model הוא אלגוריתם clustering באמצעות שילוב פרמטרים.

- ההנחה: יש כמה קבוצות, שכל אחת מהן יוצרת התפלגות גאוסיאנית.
- העולם קודם "מגריל" לאיזו קבוצה כל דגימה שייכת, ואז מגריל את הדגימה לפי ההתפלגות שלה.

מבחינה פורמלית:

- כרגיל יש לנו  $\mathcal{D} = \{x_1, \dots, x_n\}$  ב  $\mathbb{R}^d$ , אבל הפעם  $\mathcal{D}$  נוצר משילוב (mixture) של  $K$  התפלגויות גאוסיאניות שונות.

- ההסתברות השולית של  $x_i$  מוגדרת לפי סכום של  $K$  ההתפלגויות:

$$P(x_i|\theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k)$$

- הפרמטרים הם  $\theta = (\pi, \mu, \Sigma)$  כאשר:

$\pi_k$  ההסתברות להיות שייכים להתפלגות  $k$ .

$\mu_k$  הממוצע של התפלגות  $k$ .

$\Sigma_k$  מטריצת השונות המשותפת של התפלגות  $k$ .

- המטרה - למצוא  $\theta$  שממקסם את המarginal log-likelihood:

$$\arg \max_{\theta} \sum_{i=1}^n \log \left( \sum_{k=1}^K \pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k) \right)$$

גם את זה אי אפשר לפתור אנליטית, וצריך, שוב, אלגוריתם איטרטיבי:

- צעד E (expectation) - בהינתן  $\theta^{(t)}$ , מחשבים את  $\gamma_{ik}$  responsibility - ההסתברות הפוסטריורית של  $k$  היה אחראי לייצר את  $x_i$ :

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j)}$$

- צעד M (maximization):

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ik} x_i}{\sum_{i=1}^n \gamma_{ik}}$$

$$\Sigma_k^{(t+1)} = \frac{\sum_{i=1}^n \gamma_{ik} (x_i - \mu_k^{(t+1)}) (x_i - \mu_k^{(t+1)})^T}{\sum_{i=1}^n \gamma_{ik}}$$

$$\pi_k^{(t+1)} = \frac{1}{n} \sum_{i=1}^n \gamma_{ik}$$

**למידת מכונה**  
**89-2511-02**

מקליד: עידן אריה  
מרצה: ד"ר אורן גליקמן  
תאריך: 2026-06-08

- 
- תכונות:
- soft clustering - כל נקודה שייכת לכל אחד מהclusters בהסתברות מסויימת.
  - הclusters יכולים להיות גם אליפסות, לא רק מעגלים.
  - האלגוריתם מתכנס רק אסימפטוטית.
  - הסיבוכיות שלו (לכל איטרציה) היא  $O(n \cdot K \cdot d^3)$ .

## (PCA) Principal Component Analysis

האלגוריתמים הקודמים עסקו בclustering ובdensity estimation. הפעם המטרה לעשות dimensionality reduction - כלומר להקטין את מספר המימדים - למצוא פונקציה  $f: \mathbb{R}^d \rightarrow \mathbb{R}^k$  כאשר  $k \ll d$ . ההנחה היא שהנתונים, בהם באמת  $k$ -מימדיים - אבל קיבלנו יצוג  $d$ -מימדי שלו.

דוגמה: ייצוג של מנייה יכול להיות העליה והירידה שלה בכל יום - כלומר מימד לכל יום. זה מימד מאוד מאוד גדול. אבל PCA יכול להקטין את זה ל-2 מימדים (שהם לא בהכרח בחירה של אחד מהימים, אלא שילוב לינארי של הכל) וזה יאפשר לנו למצוא cluster יתר בקלות.

אפשר גם לעבוד על הציר השני של המטריצה - לייצג כל יום לא באמצעות 500 מספרים (אחד לכל מנייה) אלא למצוא מימד יותר נמוך שייצג מה קרה באותו יום.

אנחנו אמנם מאבדים מידע, אבל זה מאפשר לנו ליעל את המודלים, להציג את המידע בצורה חזותית, להוריד רעש, ובאופן כללי לדחוס את הנתונים. לפני שעושים PCA מנרמלים את הנתונים:

$$x_{i,j} \rightarrow \frac{x_{i,j} - \bar{x}_j}{\sigma_j}$$

כאשר:  $\bar{x}_j$  הממוצע של פיצ'ר  $j$ :

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{i,j}$$

$\sigma_j$  סטיית התקן של פיצ'ר  $j$ :

$$\sigma_j^2 = \frac{1}{n} \sum_{i=1}^n (x_{i,j} - \bar{x}_j)^2$$

לאחר הנרמול אפשר להניח ממוצע 0 ושונות 1.

תזכורת: אם יש לנו מרחב  $d$  מימדי ו- $d < r$ , אפשר לבחור ווקטאורי עמודה  $\{v_1, \dots, v_r\}; v_i \in \mathbb{R}^d$  שיהיו בסיס לתת-מרחב  $r$  מימדי.

• מניחים שהבסיס אורתונורמלי<sup>2</sup> - ואז  $V^T V = I_{r \times r}$ .

• תת המרחב הוא  $\text{span} \{v_1, \dots, v_n\} = \left\{ \sum_j a_j v_j : a_j \in \mathbb{R} \right\}$

• אפשר לייצג את הבסיס הזה בתור מטריצה  $V = [v_1 | \dots | v_r] \in \mathbb{R}^{d \times r}$

<sup>2</sup>אפשר להפוך את הבסיס לאורתונורמלי באמצעות Gram-Schmidt, בהנחה שהווקטורים בת"ל.

**למידת מכונה**  
**89-2511-02**

מקליד: עידן אריה  
מרצה: ד"ר אורן גליקמן  
תאריך: 2026-06-08

---

אפשר "לקודד" (encode) כל ווקטור  $x \in \text{span}(V)$  באמצעות  $V^T$ , ואז "לפענח" (decode) אותו באמצעות  $V$  כלומר  $VV^T x$  הוא projection של  $x$  לתוך  $V$  - ואם מלכתחילה  $x \in V$  אז  $VV^T x = x$ .

נשים לב:  $V^T V = I_{r \times r}$  אבל  $VV^T \neq I_{d \times d}$  כי  $V$  לא מכיל בסיס מלא ל- $\mathbb{R}^d$ .  
אם  $x \notin \text{span}(V)$  אז  $VV^T x = x' \neq x$ .

למידת מכונה  
89-2511-02

מקליד: עידן אריה  
מרצה: ד"ר אורן גליקמן  
תאריך: 2026-06-08

המטרה של PCA היא למצוא בסיס אורתונורמלי ככה שהשחזור של הדגימות ב- $\mathcal{D}$  יהיה כמה שיותר קרוב למקור:

$$\min_{V: V^T V = I} \sum_i \|V V^T x_i - x_i\|_2^2$$

הערה: אם  $r = 1$  זה זהה לרגרסייה לינארית, אבל במימדים יותר גבוהים זה לא כי הבסיס הוא יותר מקו אחד.

אם יש לנו מטריצת של  $n$  דגימות ממימד  $d$  -  $X \in \mathbb{R}^{n \times d}$  - ה sample covariance matrix היא:

$$\text{Cov}(X) = \frac{1}{n} X^T X \in \mathbb{R}^{d \times d}$$

$\text{Cov}(x)$  היא:

- סימטרית, ולכן יש לה ווקטורים עצמיים  $u_1, \dots, u_d$  ווקטורים עצמיים  $\lambda_1, \dots, \lambda_d$  ממשיים.

- היא גם positive semi-definite (PSD) ולכן כל הערכים העצמיים הם לא-שליליים.

- הווקטורים העצמיים הם אורתוגונליים  $u_i \cdot u_j = \delta_{i,j}$

כזכור, המטרה של PCA היא למזער את:

$$\min_{V: V^T V = I_{r \times r}} \sum_i \|V V^T x_i - x_i\|_2^2$$

משפט: הפתרון ל-PCA הוא מטריצה  $V$  המורכבת מווקטורים  $v_1 = u_1, \dots, v_r = u_r$  כלומר  $r$  הווקטורים עם הערכים העצמיים הכי גדולים של  $\text{Cov}(X)$ .

כלומר - כל מה ש-PCA עושה זה לחשב את  $\text{Cov}(X)$  ולקחת את  $r$  הווקטורים הכי גדולים. מה קיבלנו? בכל נקודה  $x$ , אפשר להטיל אותה ממימד  $d$  למימד  $r$  באמצעות  $V^T x$ . מה שמפסידים - ממוצע המרחקים - זה סכום הערכים העצמיים שלא השתמשנו בהם:

$$\frac{1}{n-1} \sum_i \|V V^T x_i - x_i\|^2 = \sum_{j=r+1}^d \lambda_j$$

כלומר, אם רוצים לבחור לאיזה מימד להוריד - אפשר להסתכל על הערכים העצמיים וכל עוד הם קטנים אפשר להוריד אותם. כלומר לבחור  $r$  קטן - אבל כזה שגם  $\sum_{j=r+1}^d \lambda_j$  יהיה קטן.

PCA יוצר decorrelation בנתונים. אם הטלה היא  $a = V^T x$  והטלת כל הדגימות היא  $A = X V$ , הממוצע של  $A$  הוא אפס בגלל שנירמלנו את  $X$ :

$$\sum_i a_i = V^T \sum_i x_i = V^T 0$$



**למידת מכונה**  
**89-2511-02**

מקליד: עידן אריה  
מרצה: ד"ר אורן גליקמן  
תאריך: 2026-06-08

---

השונות של  $A$  היא אלכסונית (עד כדי factor של  $n$ ):

$$A^T A = V^T X^T X V = V^T \text{Cov}(X) V = V^T V \Lambda V^T V = \Lambda$$

PCA לא רק ממזער את המרחקים - הוא גם ממקסם את השונות, שכן המימדים שכן נשארים הם אלו בהם השונות הייתה גדולה.  
כמובן - ככל ש $\lambda$  יותר קטן ככה השונות יותר קטנה. אנחנו רוצים לא להקטין את השונות יותר מדי, כדי שהמודל יהיה טוב.  
לא חייבים להגביל את עצמנו להורדות מימד לינאריות. אפשר להשתמש גם בפונקציות אחרות.  
הערה: נראה כאילו PCA למימד אחד דומה לרגרסיה לינארית, אבל:

- ברגרסיה לינארית הloss מחושב לפי מרחקים על ציר ה $Y$ .
- בPCA הloss מחושב לפי מרחקים מהקו - כלומר  $90^\circ$  מהקו, ולא  $90^\circ$  מציר ה $Y$  (שאינן באמת "ציר  $Y$ " כי זה unsupervised)