

בעיות בשימושי למידת מכונה בעולם האמיתי

קורלציה מול סיבתיות

קורלציה אינה סיבתיות - תלות סטטיסטית בין שני מאורעות - כלומר, $P(AB) \neq P(A)P(B)$ - לא אומר שאחד גורם לשני. בשביל להחליט אם יש סיבתיות, אנחנו צריכים "התערבות" - לגרום לאחד מהמאורעות בעצמנו ולראות אם זה גורם לשני.

למשל: "גשם" ו"שלולית". אם אנחנו גורמים לשלולית להיווצר, זה לא יוצר גשם. אבל אם אנחנו גורמים (איכשהו) לגשם להיווצר - זה כן יוצר שלולית.

הרבה פעמים יש בכלל confounding variable - גורם שלישי שגורם לשני המאורעות, והתלות הסטטיסטית ביניהם מגיעה משם. המודלים שראינו מסתכלים על קורלציה, לא על סיבתיות. זה יכול להיות בעייתי להשתמש בהם בשביל לעשות פעולות בעולם האמיתי.

התפלגות לא שוויונית

בעיה נוספת - נתונים בעולם לא מתפלגים אחיד. מודלים נעשים טובים ככל שיש להם יותר נתונים - מה שאומר שהם יותר טובים על דגימות שמגיעות מהרוב, ויעשה יותר טעויות כשהוא מסתכל על מיעוטים.

רמת ביטחון

יש גם נטייה לטעות בקריאה של תוצאות המודל. אם למשל softmax מקבלים 0.9 על אחד מהאפשרויות, יש נטייה להתייחס לזה כאל "ההסתברות שהמודל צודק". אבל זה לא זה - מקסימום אפשר לחשוב על זה כעל רמת הביטחון של המודל בתשובה, אבל זה בפירוש לא accuracy, והמודלים הם overconfident - הציונים שהsoftmax נותן בד"כ יותר גבוהים מהדיוק בפועל.

יש נסיונות לעשות calibration אחרי שלמדנו את המודל. למשל:

• Platt Scaling - לקחת את confidencen שהמודל הוציא ולשים אותו בתוך סיגמואיד:

$$\text{acc} = \text{sigmoid}(a \cdot y + b)$$

זה נותן לנו עוד שני פרמטרים שאנחנו צריכים ללמוד.

• Temperature Scaling - להגדיל את הטמפרטורה של softmax, מה שמקטין את רמת הביטחון.

Group fairness

היינו רוצים 3 דרישות מאלגוריתמים, כדי שיהיו הוגנים:

1. Demographic parity - לאדם יש כל מיני תכונות שאנחנו רוצים לחזות - וגם תכונות שקשורות לקבוצה אליה הוא משתייך, ואנחנו לא רוצים להפלות לפיהן. אנחנו רוצים classifier שלא יהיה תלוי בשייכות לקבוצות האלה. חשוב לשים לב שגם אם לא מאמנים אותו ישירות לפי הדברים האלה, הם יזלגו דרך תכונות אחרות.
 2. Equalized odds - מודלים עושים טעויות, גם false positive וגם false negative. אנחנו רוצים שאחוזי הטעויות לא יהיה תלוי בקבוצה.
 3. Calibration - אם המודל נתן ציון p , זה גם ההתפלגות בפועל לתשובה חיובית (כלומר כל $p\%$ ממי שקיבל ציון p הוא חיובי) בלי קשר לקבוצה.
- אי אפשר לקבל את כל שלושת התכונות ברמת הקבוצה. אבל אפשר לדרוש תכונות יותר חלשות.
- למשל: individual fairness. אם יש שני אנשים דומים, אז המרחק בין ההחלטות עליהן לא יכול להיות שונה מדי:

$$d(f(x), f(x')) \leq L \cdot d(x, x')$$

נשים לב שזה לא פותר לגמרי את בעיית האפליה, כי התכונות המפלות זולגות לתוך x . זה פשוט מעביר את הבעיה לתוך ההגדרה של פונקציית המרחק d .

לרמות מודלים

אפשר, באמצעות הוספת רעש מכוון, לגרום למודל לטעות. למשל - להוסיף רעש לתמונה שיגרום למודל לנחש ברמת ביטחון גבוהה שמדובר במשהו אחר. הרעש, כמובן, צריך להיות מחושב בתהליך אופטימיזציה ולא להיות מוגרל באקראי.

איך מוצאים את הרעש הזה? יש לנו ווקטור קלט x , משקלות w , ופלט y . עד עכשיו היינו שומרים את הקלט והפלט קבועים ועושים אופטימיזציה על w . בשביל למצוא את הרעש הדרוש, צריך לקבע את w ולחשב את הגרדיאנט לפי x . צריך, כמובן, לשמור על x קרוב יחסית ל x המקורי (למשל - עם רגולריזציה) כדי שלעין אנושית הוא ייראה כמו התמונה המקורית ורק המודל יבחין ברעש.