

פורמליזציה של קבלת החלטות בייסיאניות

• יש לנו מצבים $\Omega = \{\omega_i\}$. זה העולם האמיתי - אבל אנחנו לא יודעים בוודאות מה המצב האמיתי.

• יש לנו תצפיות: $S_n = \{x_1, \dots, x_n\}$

• יש לנו מודל התסברותי $P(S_n|\omega)$ ו $P(\omega)$. מניחים ידע מלא על ההסתברויות האלה.

• פעולות אפשריות: $A = \{\alpha_1, \dots, \alpha_k\}$

• עלויות: $\Lambda = \{\lambda(\alpha_k|\omega_j)\}$

אנחנו רוצים לבחור את הפעולה בהינתן התצפיות.

$$P(\omega|x) = \frac{P(x|\omega)}{P(x)}P(\omega)$$

סיכון מותנה

הסיכון המותנה הוא תוחלת העלות של פעולה α_k בהינתן תצפית x_i :

$$R(\alpha_k|x_i) = \sum_{\omega_j \in \Omega} \lambda(\alpha_k, \omega_j) \cdot P(\omega_j|x_i) = \mathbb{E}_{P(\omega_j|x_i)} [\lambda(\alpha_k|\omega_j)]$$

העלות של אסטרטציה $\alpha(S_n)$ היא:

$$R(\alpha(S_n)) = \sum_{x_i \in S_n} R(\alpha(x_i)|x_i) \cdot P(x_i) = \mathbb{E}_{P(x_i)} [R(\alpha(x_i)|x_i)]$$

מה העלות לפעולה מסויימת בהינתן תצפית.

עלות Mean Squared Error - MSE

$$\lambda(a, y) = (a - y)^2$$

העלות נקבעת לפי המרחב (ברביוע) בין התשובה שאנחנו נותנים a לתשובה האמיתית y .
בוחרים פעולה a שתמזער את ה-MSE.
זה אמור לצאת הממוצע (בהתפלגות גאוסיאנית קל להוכיח את זה)

איך זה מתקשר לקורס?

קבלת החלטות בייסיאנית מניחה שאנחנו יודעים את ההתפלגויות. במציאות זה לא ככה - הבעיה של למידת מכונה שאנחנו לא יודעים, אלא יש לנו רק אוסף של דוגמאות ממנו אנחנו אמורים ללמוד.

הtradeoff בין הטייה (bias) לשונות (variance)

- הטייה - כמה התחזית שלנו מתרחקת מהממוצע.
- אנחנו לא באמת יכולים לדעת אותה בוודאות, כי אנחנו לא יודעים מה הממוצע האמיתי.
- שונות - כמה התחזיות שלנו שונות אחת מהשנייה.

פרוק של MSE

MSE הן לוקח בחשבון את שניהם:

- בהינתן סט דוגמאות אימון $S_n = \{(x_i, y_i)\}_{i=1}^n$
- S_n הוא n דוגמאות מתוך התפלגות D .
- לכל דגימה (x, y) , התווית y אינה ידועה.
- אנחנו רוצים לחזות את y בהמצעות היפוטזה $h(x) = h(x; S_n)$
- mean squared error היא תוחלת של כמה אנחנו טועים על כל הדגימות בעולם (לא רק על סט האימון שלנו):

$$\mathbb{E}_{(x,y) \sim D} [(y - h(x))^2]$$

אפשר לסמן תוחלות על כל התוויות האפשריות:

$$\mathbb{E}_{(x,y)} [\cdot] := \mathbb{E}_{(x,y) \sim D} [\cdot]$$

ואפשר גם על כל אוספי האימון האפשריים:

$$\mathbb{E}_{S_n} [\cdot] := \mathbb{E}_{S_n \sim D^n} [\cdot]$$

לנו יש את התוחלת על סט האימון שלנו $\mathbb{E}_{(x,y)} [(y - h(x))^2]$

ואפשר להגיע מזה ל:

$$\mathbb{E}_{(x,y) \sim D} [(y - h(x))^2] = \underbrace{\mathbb{E}_{(x,y)} [(y - \mathbb{E}_{S_n} [h(x)])^2]}_{\text{Squared Bias}} + \underbrace{\mathbb{E}_{(x,y)} [(\mathbb{E}_{S_n} [h(x)] - h(x))^2]}_{\text{Variance}}$$

- איך אפשר להקטין את ההטייה?
 - אפשר לבחור h יותר מורכבת (למשל פולינום במקום פונקציה לינארית)
- איך אפשר להקטין את שונות?
 - להשתמש ביותר נקודות אימון
 - להגביל את h

יש tradeoff ביניהם, ורוצים לבחור sweet spot כדי למזער את ה-MSE.

Overfitting ו Underfitting

יש לנו תהליך אימון. יש לנו:

- סט אימון - training set
 - סט אימות - validation set - ששומרים בצד
 - סט בדיקה - test set - אותו אין לנו, זה הסט של המידע שהמודל יופעל עליו
- אנחנו רוצים להעריך את ה-loss (פונקציית המחיר) על סט הבדיקה. עושים את זה באמצעות סט האימות.
- ככל שהמודל יותר מורכב, השגיאה מול סט האימון תהיה יותר נמוכה. אבל לא בהכרח לסט האימות:

- Underfitting, יש שגיאה גבוהה גם בסט האימון וגם בסט האימות.
 - ההטייה תהיה גבוהה
- Good fit יש שגיאה נמוכה בשניהם
- Overfitting יש שגיאה נמוכה בסט האימון אבל שגיאה גבוהה בסט האימות.
 - השונות תהיה גבוהה

הארה: חוץ מ-underfitting ו overfitting, תמיד יכול להיות שקיבלנו סט אימון שאין בו סיגנל, רק רעש.

איך נמנעים?

• Underfitting:

- המודל פשוט מדי.
- להגדיל את מורכבות המודל
- לשפר את האופטימיזציה

• Overfitting:

- המודל מסובך מדי
- או שאין מספיק נקודות בסט האימון
- אפשר לבחור מודל פחות expressive
- אפשר להשתמש בparameter regularization

אימות מוצלב K-fold

יש לנו הרבה פרמטרים שמשפיעים על האימון. אנחנו רוצים לבחור אותם - ועושים את זה לפי סט האימות.

אבל אם יש לנו סט אימון קטן, יש לנו בעיה - אנחנו לא רוצים לחתוך אותו יותר מדי, וגם כאשר חותכים - סט האימות שנחתוך מתוכו יהיה עוד יותר קטן.

הפתרון - cross validation

אפשר לחתוך בכל פעם validation set אחר מתוך training set, ולעשות ממוצע כדי להעריך את הפרמטרים שבחרנו.