

תזכורת: • Parameter Estimation

בהינתן סט פרמטרים, אנו יודעים מה התפלגות התצפיות. אנחנו רוצים להעריך את הכיוון השני - מה ההסתברות לפרמטרים בהתאם להתפלגות שקיבלנו.

Bayes Decision Theory באמצעות Parameter Estimation

ממזערים את התוחלת של העלות (שמוגדרת לפי גודל הטעות)

$$P(\theta|X) = \arg \max_{\theta} \frac{P(X|\theta)}{P(X)} P(\theta)$$

מוצאים את θ באמצעות גזירה.

Maximum Likelihood Estimation

מגדירים את העלות בתור הlikelihood:

$$\theta_{ML} = \arg \max_{\theta} P(S_n|\theta) = \arg \max_{\theta} \sum_i \log P(x_i|\theta)$$

ההבדל העיקרי בין זה לבין Bayes Decision Theory היא שכאן מתעלמים מ- $P(\theta)$ - מניחים שאין prior, או שהוא אחיד¹.

הערה: משתמשים ב-log כי יותר נוח לגזור סכומים מאשר מכפלות.

PAC Learning

אנחנו רוצים למצוא מודל $h: x \mapsto \hat{y}$ שחווה $\hat{y}$ שמתאים ל- y האמיתי.

יש טעות אמיתית $Err_D(h) = \mathbb{E}_{P(x,y)} [l(h(x), y)]$.

יש את הטעות האמפירית (או טעות אימון) $Err_{S_n}(h) = \frac{1}{n} \sum_{i=1}^n l(h(x_i), y_i)$

הרעיון של PAC (Probably Aproximtately Correct)

הגדרה: קבוצת היפותזות $\mathcal{H}$ היא PAC learnable אם קיים אלגוריתם A אשר מוצא היפותזה $h^* = A(S_n)$ לכל סט דוגמאות S_n המקיים: לכל $\epsilon, \delta > 0$, קיים $N(\epsilon, \delta)$ עבורו לכל $n > N(\epsilon, \delta)$ ולכל התפלגות D מתקיים

$$Pr[Err_D(A(S_n)) < \epsilon] > 1 - \delta$$

¹ גם אין $P(X)$ - אבל זה לא משפיע על התוצאה, כי הוא אינו תלוי ב- θ .
² למרות *, לא מדובר כאן על ההיתפוזת ה"אמיתית". יש יותר מהיפותזה אחת שיכולה לקיים את התכונה הזאת - ההיפותזה האמיתית בהכרח מקיימת אותה.

למידת מכונה
89-2511-05

מקליד: עידן אריה
מתרגל: ניר בן ארי
תאריך: 2026-04-13

במילים: בהינתן מספיק data, סביר להניח (ϵ) שנגיע להיפותזה נכונה בקירוב (δ).
ה $N(\epsilon, \delta)$ נקרא Sample Complexity - מספר הנקודות המינימלי הדרוש כדי להגיע לקירוב הרצוי.

תכונות: • $N(\epsilon, \delta)$ מונוטוני לא-עולה עבור הפרמטר הראשון.
אינטואיציה: אם מספר הנקודות מספיק עבור הטעות הקטנה, הוא בהכרח מספיק גם עבור הטעות הגדולה.