מקליד: עידן אריה
מתרגל: ניר בן ארי
תאריך: 2026-05-25

למידת מכונה
89-2511-05

Multilayer Perceptron

בForward Propogation, ווקטור הקלט $\mathbf{x}$ נכנס לשכבה הראשונה $W_1\mathbf{x} + \mathbf{b}_1$, והופך ל$\mathbf{z}_1$. מפעילים עליו פונציית אקטיבציה לא־לינארית שעובדת איבר איבר (למשל סיגמואיד) שהופכת אותו ל$\mathbf{h}_1$. $\mathbf{h}_1$ נכנס לשכבה השנייה $W_2\mathbf{h}_1 + \mathbf{b}_2$ והופך ל$\mathbf{z}_2$, וכן הלאה.
בBackward Propogation, מחשבים את הגרדיאנט על הloss אחורה לפי כלל השרשרת:

$$\frac{\partial \mathcal{L}}{\partial W_1} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial z_n} \frac{\partial z_n}{\partial h_{n-1}} \frac{\partial h_{n-1}}{\partial z_{n-1}} \cdots \frac{\partial z_2}{\partial h_1} \frac{\partial h_1}{\partial z_1} \frac{\partial z_1}{\partial W_1}$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}_1} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial z_n} \frac{\partial z_n}{\partial h_{n-1}} \frac{\partial h_{n-1}}{\partial z_{n-1}} \cdots \frac{\partial z_2}{\partial h_1} \frac{\partial h_1}{\partial z_1} \frac{\partial z_1}{\partial b_1}$$

ולהפעיל gradient descent:

$$W_1^t = W_1^{t-1} - \eta \frac{\partial \mathcal{L}}{\partial W_1} \qquad b_1^t = b_1^{t-1} - \eta \frac{\partial \mathcal{L}}{\partial b_1}$$

אותו דבר על כל השכבות (מתחילים מהשכבה האחרונה). בכל איטרציה עוברים על כל השכבות.