

למידה לא מופקחת - Unsupervised Learning

עד עכשיו היה לנו תווית (label) לכל דוגמה (sample). מה קורה כשאין תוויות?

- עדיין רוצים למצוא פיצ'רים שיתארו לנו כמה שיותר טוב את הנתונים.
- עדיין רוצים לחלק לקבוצות - אבל אנחנו לא יודעים מה הקבוצות

Principal Component Analysis (PCA)

זהו אחד האלגוריתמים השימושיים ללמידה לא מופקחת.

המטרה: להוריד מימדים

הדרך: לוקחים את הצירים עם הכי הרבה variance.

זה אומר שמבצעים התמרה לינארית - סיבוב, כדי לשנות את מערכת הצירים - ואז מורידים חלק מהצירים.

אפשר לכתוב את את מטריצת השונות המשותפת $Cov(X) = U\Lambda U^T$ כאשר העמודות של U הן הווקטורים העצמיים $u_1, \dots, u_d$. Λ היא אלכסונית, ומניחים שהיא ממוינת בסדר יורד $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ (הערך העצמי המתאים ל- u_i)

מניחים שהממוצע הוא אפס.

לפי זה אפשר למצוא מטריצת סיבוב **לא ריבועית** - כלומר כזאת שמקטינה (או מגדילה - אבל אנחנו רוצים להקטין) את מספר המימדים.

הערה: אפשר להשתמש ב-PCA גם כשיש תוויות - לצורך preprocessing.

1. מפשט את החישוב.
2. פחות אפשרות ל-overfitting, כי עובדים במימדים יותר נמוכים.
3. פחות רעש.

- פוגע:
1. אנחנו לא יודעים מה הפיצ'רים שחשובים לנו. יכול להיות שדווקא המימדים שהסרנו מכילים מידע קריטי - אולי ההפרדה היא דווקא על המימדים עם השונות המשותפת הנמוכה?
 2. PCA הוא לינארי, ואם הנתונים לא ניתנים להפרדה לינארית PCA לא יעזור.

אפשר לכתוב את PCA כבעיית אופטימיזציה - הטלה למימד נמוך יותר שממזערת את השגיאה הריבועית כשמנסים לשחזר את הנקודות:

$$\arg \min_{\substack{V \in \mathbb{R}^{d \times r} \\ V^T V = I}} \sum_{i=1}^n \|V V^T x_i - x_i\|_2^2$$

אפשר - ואף מקובל - לנרמל את הפיצ'רים לפני שעושים PCA ככה שלכל ציר תהיה שונות 1. PCA עדיין יעבוד טוב - כי השונות המשותפת לא תהיה אחידה.

K Means

למרות שאין לנו תוויות, נרצה למצוא איזו הפרדה - קבוצות (clusters) של נקודות שקרובות יותר אחת לשנייה מאשר לקבוצות אחרות.

נסמן:	N	מספר ה data points.
	K	מספר ה clusters (קבוצות)
	z_j	centroid של קבוצה j .
	C_j	אוסף הנקודות ששייך לקבוצה j .

k-means הוא תהליך איטרטיבי:

1. מתחילים עם K סנטרואידים אקראיים.
2. משייכים כל נקודה לסנטרואיד הכי קרוב.
3. מעדכנים את הסנטרואידים לפי הנקודות שהן קיבלו - כלומר

$$z_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

4. חוזרים ל2 וממשיכים עד שיתכנס.

איך מאתחלים את הסנטרואידים? צריך אלמנט של אקראיות:

- אפשר לבחור נקודות אקראיות.
- אפשר לבחור סיווג אקראי של הנקודות, ולקחת את הסנטרואידים שלה.

תכונות של k-means:

- לא מפוקח
- צריך לקבוע את K
- תלוי במטריקה
- מניח שה clusters הם כדוריים, ובערך באותו גודל ואותה צפיפות.
- רגיש ל outlier

איך משערכים clustering?

$$\text{cost}(z_1, \dots, z_k; C_1, \dots, C_k) = \min_{C_1, \dots, C_k} \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - z_j\|_2^2 = \sum_{i=1}^n \min_{j=1, \dots, k} \|x_i - z_j\|_2^2$$

אבל זה תלוי ב K - ככל שה K יהיה יותר גדול, ככה ה cost יהיה יותר נמוך. כמובן - זה לא אומר שהמודל יותר טוב. צריך לבחור K שמתאים לתוויות (למרות שאין תוויות)

למידת מכונה
89-2511-05

מקליד: עידן אריה
מתרגל: ניר בן ארי
תאריך: 2026-06-08

הערה: עבור $K = 2$ מקבלים הפרדה לינארית, שכן ישנו ישר, שעובר בין שני הסנטרואידים במרחק שווה, ולכן כל הנקודות מצד אחד שלו קרובות יותר לאותו סנטרואיד.

אלגוריתם k-means מובטח שיתכנס. אפשר לחשוב עליו כאל תהליך מינימיזציה מתחלף:

• בהינתן μ , למצוא $r_{i,j}$ שממזער את $g(\mu, r)$. זהו הassignment step.

• בהינתן $r_{i,j}$, למצוא μ שממזער את $g(\mu, r)$. זהו הupdate step.

האלגוריתם מתכנס שכן כל שלב ממזער את המטרה, שהיא:

$$\min_{\mu} \min_r g(\mu, r) = \min_{\mu} \min_{r_{i,j}} \sum_{i,j} r_{i,j} \|x_i - \mu_j\|^2$$