

Multi-Armed Bandits

הכי קל לראות את הבעיות האלה בתור קזינו, ואפשר לראות כל מיני סוגים של מטרות (תגמול לאורך זמן, ללמוד את ההתפלגות, וכו')
בבעית Multi-Armed Bandit:

- יש רק מצב אחד.
- התגמולים סטוכסטיים
- אנחנו לא יודעים מראש את התפלגות התגמולים
- אנחנו רוצים למצוא את התוחלת הכי טובה - כלומר את הידית שנותנת בתוחלת הכי הרבה כסף.

הגדרה: MAB הוא $\langle \mathcal{A}, K, \mathcal{D}, R, T \rangle$ כאשר:

- $\mathcal{A} = \{1, 2, \dots, K\}$ זה הפעולות (הידיות של המכונה בקזינו)
- לכל ידית i יש התפלגות $D_i \in \mathcal{D}$ עם ממוצע $\mu_i = \mathbb{E}[r|i]$. ההתפלגות לא ידועה.
- אינטראקציות: בכל סיבוב $t = 1, \dots, T$, בוחרים ידית $a_t \in \mathcal{A}$ וצופים בתגמול $r_{t,a_t} \sim D_{a_t}$

$$\max \mathbb{E} \left[\sum_{t=1}^T r_{t,a_t} \right] \quad \text{המטרה היא למקסם את תוחלת התגמול הכולל:}$$

בכל סיבוב, צריך לבחור בין:

- exploration - לנסות ידיות שונות כדי ללמוד על התפלגויות התגמולים.
 - exploitation - לבחור את הידית שנראית - לפי הידע הנוכחי - שתביא לנו את הרווח הכי גדול.
- יש כאן tradeoff - אם עושים יותר מדי exploration מבזבזים זמן, ואם עושים יותר מדי exploitation אז עלולים לפספס ידית יותר טובה.
בשביל להגדיר איזה אלגוריתם הוא טוב, משתמשים ב"חרטה" - כמה אנחנו מפסידים לעומת התגמול האופטימלי μ^* :

$$\text{Regret}(T) = T \cdot \mu^* - \mathbb{E} \left[\sum_{t=1}^T r_{t,l_t} \right]$$

אלגוריתם ϵ -first

מחלקים את האופק T לשני חלקים:

- ב ϵT הצעדים הראשונים עושים exploration.
 - פשוט מנסים את כל הידיות בהתפלגות אחידה.
 - ב $(1 - \epsilon)T$ הצעדים הנותרים עושים exploitation.
- האלגוריתם הזה לא פועל טוב

אלגוריתם ϵ -greedy

כאן, במקום לחלק לשני שלבים, בכל שלב מחליטים לעשות exploration בהסתברות ϵ וexploitation בהסתברות $1 - \epsilon$.

- יתרונות: לומדים גם בסיבובי exploitation.
 - לא תלויים ב- T - יכול לעבוד גם עבור אופק אינסופי.
 - אפשר לשנות את ϵ במהלך הריצה.
- בד"כ נרצה להקטין את ϵ עם הזמן - למשל $\epsilon_t = \frac{1}{t}$ או $\epsilon_t = \frac{c}{\sqrt{t}}$.

Upper Confidence Bound - UCB

האלגוריתמים לפי ϵ שראינו לא מתחשבים במידע שיש לנו על ההתפלגויות כדי לבחור אם לעשות exploration או exploitation (ואיזו ידיה כדאי לחקור).
UCB נותן לכל יד ערך לפי:

- הממוצע שלו לפי מה שדגמנו.
 - בונוס, שצריך להיות גדול עבור ידיה שלא דגמנו הרבה וקטן עבור ידיה שנדגמו הרבה ואנחנו די בטוחים בשיערוך שלהן.
- פשוט נעדכן:

$$UCB[i] \leftarrow \hat{\mu}[i] + \sqrt{\frac{2 \ln t}{n[i] + 1}}$$

- כאשר:
- $\hat{\mu}[i]$ - הממוצע הידוע לנו כרגע לכל ידיה.
 - t - כמה צעדים כבר עשינו.
 - $n[i]$ - כמה פעמים משכנו בכל ידיה.
- ואז בוחרים את הידיה עם ה- $UCB[i]$ הכי גדול.
האלגוריתם הזה מאוד מוצלח, ועובד לכל התפלגות.

Sequential Halving

אנחנו לא רוצים למקסם תוחלת כאן, אלא למצוא את הידיה הכי טובה. לכן, במשך $\log_2 K$ סיבובים:

- נבחר כמה מהצעדים הנותרים לנסות כל ידיה מתוך S (הידיה שעוד לא פסלנו).
 - מחשבים $\hat{\mu}_i$ אמפירי.
 - פוסלים חצי מהידיה (מסירים אותן מ- S) שנתנו $\hat{\mu}_i$ יותר נמוך מהחצי השני.
- אחרי הסיבוב האחרון, נישאר עם ידיה אחת - שהיא תהיה התשובה.
בחירת מספר הנסיונות היא:

$$t_r \leftarrow \left\lceil \frac{T}{|S_r| \cdot R} \right\rceil$$